

Neuralangelo: High-Fidelity Neural Surface Reconstruction

論文深度整理 | 依章節、方法、實驗、附錄與技術重點整理

來源：使用者提供之 neuralangelo.pdf；論文版本 arXiv:2306.03092v2，2023-06-12

一頁總結

Neuralangelo 的核心不是單純把 Instant-NGP hash grid 接到 SDF，而是解決 hash encoding 在 SDF 高階導數訓練中的局部反傳問題。它用 numerical gradients 讓 eikonal / curvature supervision 能跨越多個 grid cell，再用 progressive level-of-details 避免 finer hash grids 被早期粗尺度目標污染。結果是在不使用 depth、segmentation 或 SfM point supervision 的條件下，得到更高品質的 dense 3D surface reconstruction。

文件閱讀地圖

- 第 1–2 章：說明問題背景、既有 photogrammetry / NeRF / neural surface methods 的限制。
- 第 3 章：論文核心方法，包括 SDF rendering、hash encoding、numerical gradient、progressive LoD 與總 loss。
- 第 4 章：實驗設計與結果，涵蓋 DTU、Tanks and Temples、level-of-details 與主要消融。
- 附錄：補充 hyperparameters、in-the-wild 實驗、mask 修正、color network、計算時間與 Fourier encoding 推導。
- 最後整理：方法優缺點、與實作或報告時最應該掌握的觀念。

面向	論文答案	為什麼重要
輸入	多視角 RGB 影像與 camera poses。	不需要 depth、segmentation、SfM sparse points 作為訓練監督，部署門檻較低。
場景表示	SDF MLP + multi-resolution hash encoding。	SDF 提供明確表面；hash grid 提供高容量細節。
主要困難	hash encoding 的 analytical gradient 對位置有局部性與不連續。	eikonal 與 curvature loss 依賴高階導數，若梯度只更新局部 cell，表面會 noisy。
核心解法	numerical gradients + progressive hash activation。	前者提供跨 cell smoothing，後者控制由粗到細的幾何學習。
主要成果	DTU mean Chamfer 0.61 mm；Tanks mean F1 0.50。	在重建精度與 view synthesis 上都優於主要 baseline。

Abstract 與研究目標

論文的目標是從多視角 RGB 影像重建高保真 3D surface。作者指出，neural surface reconstruction 已經能透過 image-based neural rendering 取得 dense surfaces，但既有方法對真實世界場景的細節恢復仍不足。Neuralangelo 將 multi-resolution 3D hash grids 的表徵能力與 neural surface rendering 結合，並用兩個設計讓 hash grid 適合 SDF surface reconstruction：numerical gradients 與 coarse-to-fine optimization。

- 研究問題：如何只用 RGB 多視角影像，重建可用於 3D asset、AR/VR/MR、robotics mapping 的 dense surface。
- 既有問題：MLP-based SDF 表面平滑但細節有限；hash grid 表達力強但直接套到 SDF 會訓練不穩。
- 主要貢獻一：把 Instant-NGP 類 hash encoding 自然整合到 neural SDF representation。
- 主要貢獻二：提出 numerical gradients 處理高階導數，使 eikonal / curvature regularization 不受局部 cell 限制。
- 主要貢獻三：提出 progressive levels of details，使 geometry 由粗到細穩定恢復。

1. Introduction：問題背景

傳統 multi-view stereo 依賴不同視角之間的 photometric consistency。當場景有大面積同色、重複紋理、強光照變化、自動曝光或非 Lambertian 材質時，對應點與深度估計會變得不可靠，最終 surface 會缺失或 noisy。Neural surface reconstruction 透過 implicit function 與 volume rendering 改善這些限制，因為 MLP 的連續性使表面能在空間中平滑插值。

但作者指出，既有 MLP representation 的重建細節不會隨著 MLP capacity 很好地擴展。Instant-NGP 的 multi-resolution hash encoding 以低記憶體成本提供高解析度 feature grid，適合表達細節。然而，hash grid 的離散 cell / hash table 結構使其高階導數行為與傳統 Fourier encoding MLP 不同，這正是 Neuralangelo 要解決的核心。

Introduction 的真正論點

Neuralangelo 不是把更強的 encoding 放進 NeuS 就結束；它的論點是：hash encoding 的表達力必須搭配適合 surface regularization 的導數估計與訓練排程，否則高解析度 capacity 會轉化成 noisy geometry，而不是高保真表面。

2. Related Work：相關研究脈絡

2.1 Multi-view Surface Reconstruction

- 早期方法使用 volumetric occupancy grid，根據多視角投影後的顏色一致性標記 voxel 是否 occupied。
- photometric consistency 在真實世界不穩：auto-exposure、反光、非 Lambertian surface、陰影都會破壞顏色一致。
- 後續方法常先用 MVS 產生 point cloud，再做 dense surface reconstruction；缺點是結果受 point cloud 品質上限限制。
- learning-based MVS 以 learned features 與 cost volume 改善點雲，但 cost volume resolution 仍限制幾何細節。

2.2 NeRF 與 Density-based Rendering

- NeRF 用 MLP 將 3D position 映射到 density 與 color，透過 volume rendering 合成像素顏色。
- NeRF 的 novel view synthesis 很強，但 density field 沒有明確 surface；常用 threshold 抽 isosurface。
- density level set 缺乏直接 geometric constraint，因此抽出的 mesh 可能 noisy，且不一定符合真實場景結構。

2.3 Neural Surface Reconstruction

- IDR、NeuS、VolSDF 等方法使用 occupancy 或 SDF，讓 surface 定義為 zero-level set，幾何意義更明確。
- NeuS / VolSDF 透過特定轉換把 SDF 轉成 volume density / opacity，因此能用 image rendering loss 訓練。
- 部分後續工作追求即時性但犧牲 fidelity；另一些方法加入 depth、segmentation、SfM point cloud 或 patch warping 作輔助。
- Neuralangelo 的定位是：不使用這些 auxiliary inputs，而是從 representation 與 optimization 角度提升 fidelity。

3. Approach : 方法完整拆解

方法總覽

Neuralangelo 沿著 camera ray 取樣 3D points，使用 multi-resolution hash encoding 取得位置特徵，SDF MLP 預測 signed distance，color MLP 預測顏色，再使用 NeuS 的 SDF-based volume rendering 合成影像。訓練時以 RGB loss、eikonal loss、curvature loss 共同最佳化。

3.1 Preliminaries : Volume Rendering

NeRF 類 volume rendering 對每條 ray 取 N 個 sample。第 i 個 sample 位於 camera center o 沿 ray direction d 的距離 t_i ，網路預測 density σ_i 與 color c_i 。rendered color 是所有 sample color 的加權和，權重 w_i 由 transmittance T_i 與 opacity α_i 決定。

符號	意義	直觀解釋
$\hat{c}(o,d)$	ray 對應 pixel 的 rendered color	模型合成出的像素顏色
$w_i = T_i \alpha_i$	第 i 個 sample 的 rendering weight	該點對最終像素顏色的貢獻量
$\alpha_i = 1 - \exp(-\sigma_i \delta_i)$	ray segment opacity	該段是否吸收或散射光線
T_i	accumulated transmittance	光線抵達第 i 點前尚未被遮擋的比例
L_{RGB}	rendered image 與 input image 的差異	主要 supervision 來源

3.1 Preliminaries : SDF Volume Rendering

SDF 表面定義為 $S = \{x \in \mathbb{R}^3 \mid f(x)=0\}$ 。NeuS 將 SDF 透過 logistic / sigmoid CDF 轉成 opacity，使 SDF representation 能使用 volume rendering 由影像反向最佳化。Neuralangelo 沿用這個 SDF-based rendering formulation，因此表面不再是 density threshold 的 heuristics，而是 SDF 的 zero-level set。

3.1 Preliminaries : Multi-resolution Hash Encoding

Instant-NGP 的 hash encoding 使用 L 個不同解析度的 grid。給定位置 x ，在每個解析度 V_l 下轉成 $x_l = x \times V_l$ ，找到所在 grid cell 的 corner hash entries，經 trilinear interpolation 得到該層 feature $\phi_l(x_l)$ ，再將所有層 feature concat 成 $\phi(x)$ 。這個 feature 送入 shallow MLP。

- 優點：記憶體不是隨完整 voxel grid 立方成長，而是受 hash table size 控制。
- 優點：高解析度 feature 能表達細節，MLP 可以很淺，訓練與 inference 較快。
- 與 octree / hierarchical sparse voxel 差異：hash encoding 沒有嚴格空間階層，因此 fine level 有機會修正 coarse level 漏掉的 surface。
- 代價：hash collision 與 cell-local interpolation 造成導數行為特殊，這會影響 SDF regularization。

3.2 Numerical Gradient : 為什麼需要它

SDF 必須滿足 eikonal equation： $\|\nabla f(x)\| = 1$ 。訓練 neural SDF 時通常會加入 eikonal loss，這需要對 SDF prediction 做關於位置的梯度計算，並且在反傳時形成 double backward。傳統 MLP / Fourier encoding 的 analytical gradient 在空間中連續；但 hash encoding 的位置導數會被 grid cell 邊界切斷。

做法	梯度反傳範圍	表面效果	論文觀察
Analytical gradient (AG)	只更新當前 sample 所在局部 hash grid cell corners。	容易產生 noisy surface 與 normal discontinuity。	DTU / Tanks 消融都顯示 AG 表面品質差。
AG + Progressive activation	仍受局部 cell 限制，只是延後啟用高解析度。	比 AG 好，但無法根治 normal 不連續。	改善有限。
Numerical gradient (NG)	若 step size ϵ 大於 cell size，會涵蓋多個 grid cells。	大尺度表面更平滑，但單獨使用會抹掉細節。	smoothness 明顯改善。
NG + Progressive activation	先大尺度平滑，再逐步釋放細節。	同時得到平滑 surface 與高頻細節。	Neuralangelo 最終設定。

Numerical Gradient 的計算

對 sample point $x_i=(x_i, y_i, z_i)$ ，作者沿 canonical coordinate 的 $x/y/z$ 三軸各取正負兩個偏移點。以 x 軸為例： $\nabla_x f(x_i) \approx [f(x_i + \epsilon_x) - f(x_i - \epsilon_x)] / (2\epsilon)$ 。三軸共需要 6 個額外 SDF query。當 ϵ 足夠大時，這些 query 跨越不同 hash grid cells，eikonal loss 的反傳就不再只落在單一 cell 上。

3.3 Progressive Levels of Details

- Step size ϵ ：訓練初期設為最粗 hash grid cell size，讓 normal 在大尺度上平滑一致；之後依 hash grid size 指數式降低。
- Hash grid resolution V ：初期只啟用 coarse hash grids；當 ϵ 降到某層 grid cell size 時，再啟用對應的 finer resolution。
- 避免 relearning：若所有 fine grids 一開始啟用，它們會先被大 ϵ 的 coarse objective 平滑化，後期需要 unlearn 再 relearn 細節，可能失敗。
- Weight decay：對所有參數使用 weight decay，避免某單一 resolution feature 主導最後結果。

3.4 Optimization : 總 Loss

Loss	目的	細節
L_{RGB}	讓 rendered image 符合輸入影像。	主要 image supervision；不需要 depth 或 segmentation 作訓練訊號。
L_{eik}	讓 SDF 滿足 $\ \nabla f(x)\ \approx 1$ 。	surface normal 由 numerical gradient 計算，改善 hash encoding 的局部性。
L_{curv}	降低 mean curvature，作為表面 smoothness prior。	用 discrete Laplacian 計算；因 hash trilinear interpolation 的二階 analytical gradient 幾乎到處為 0。
總 Loss	$L = L_{RGB} + w_{eik} L_{eik} + w_{curv} L_{curv}$ 。	MLPs 與 hash encoding end-to-end joint optimization。

4. Experiments : 實驗設計與結果

Datasets 與 Metrics

資料集	內容	Ground Truth	評估
DTU	15 個 object-centric scenes ; 每個 scene 有 49 或 64 張 robot-held monocular RGB images 。	Structured-light scanner 。	Chamfer distance 、 PSNR 。
Tanks and Temples	6 個 large-scale indoor/outdoor scenes ; 每個 scene 有 263–1107 張 hand-held RGB images 。	LiDAR sensor 。	F1 score 、 PSNR 。

Implementation Details

項目	設定
Hash resolution	2^5 到 2^{11} , 共 16 levels 。
Hash entry channels	每個 hash entry channel size = 8 。
Max hash entries	每個 resolution 最多 2^{22} entries 。
初始 active levels	DTU : 4 層 ; Tanks and Temples : 8 層 , 因場景尺度不同 。
Progressive activation	每 5000 iterations 啟用一個新 hash resolution , 條件是 ϵ 等於其 grid cell size 。
Auxiliary inputs	訓練過程不使用 segmentation 、 depth 或 sparse point supervision 。

4.1 DTU Benchmark

DTU 結果顯示 Neuralangelo 在平均 Chamfer distance 與 PSNR 上都取得最佳表現。它不一定在每個單獨 scene 都第一, 但整體重建精度與影像合成品質都比主要 baseline 更穩定。

方法	Mean Chamfer distance ↓	Mean PSNR ↑	備註
NeRF	1.49 mm	30.65	density-based surface , 幾何不穩 。
VolSDF	0.86 mm	30.38	SDF-based rendering 。
NeuS	0.84 mm	29.79	主要 neural SDF baseline 。
HF-NeuS	0.77 mm	—	concurrent high-fidelity baseline 。
RegSDF	0.72 mm	25.31	需要 SfM 3D points 。
NeuralWarp	0.68 mm	—	需要 patch warping / co-visibility 。
AG	0.88 mm	30.55	analytical gradient 消融 。
AG+P	0.73 mm	31.17	analytical gradient + progressive activation 。
NG	0.65 mm	31.47	numerical gradient ; 平滑但細節較弱 。
NG+P (Ours)	0.61 mm	33.84	完整 Neuralangelo 。

DTU : Neuralangelo per-scan 結果

Scan	Chamfer ↓	PSNR ↑	觀察
24	0.37	30.64	大幅優於多數 baseline。
37	0.72	27.78	較 NeuralWarp 略差於 Chamfer，但 rendering 明顯提升。
40	0.35	32.70	平滑表面表現好。
55	0.35	34.18	高 PSNR。
63	0.87	35.15	能保留 pumpkin vine 等細節。
65	0.54	35.89	重建與 rendering 都強。
69	0.53	31.47	高反光材質仍可能漏細節，附錄指出這是弱點。
83	1.29	36.82	mask 問題影響評估；附錄重新標註後結果改善。
97	0.97	30.13	中等表現。
105	0.73	35.92	高 rendering 品質。
106	0.47	36.61	細節與渲染都佳。
110	0.74	32.60	穩定。
114	0.32	31.20	Chamfer 很低。
118	0.41	38.41	statue face 等細節較清楚。
122	0.43	38.05	簡單 diffuse/texture 場景，改進幅度較小。

DTU 消融解讀

- AG : coarse surface 仍有 artifacts，說明 analytical gradient 的 locality 是根本問題。
- AG+P : progressive activation 不能補救 analytical gradient 的局部反傳限制。
- NG : 表面更平滑，但因為 coarse smoothing 過強，細節被抹掉。
- NG+P : 先用 numerical gradient 取得穩定大尺度表面，再逐步啟用 fine hash levels 捕捉細節。

4.2 Tanks and Temples

Tanks and Temples 是更大尺度、較真實的 indoor/outdoor 場景。論文比較 NeuS、NeuralWarp、COLMAP 與消融版本。因 COLMAP 與 NeuralWarp 不支援 view synthesis，PSNR 僅與 NeuS / AG / NG 類方法比較。

Scene	Ours F1 ↑	NeuS F1	COLMAP F1	Ours PSNR ↑	NeuS PSNR
Barn	0.70	0.29	0.55	28.57	26.36
Caterpillar	0.36	0.29	0.01	27.81	25.21
Courthouse	0.28	0.17	0.11	27.23	23.55
Ignatius	0.89	0.83	0.22	23.67	23.27
Meetingroom	0.32	0.24	0.19	30.70	25.38
Truck	0.48	0.45	0.19	25.43	23.71
Mean	0.50	0.38	0.21	27.24	24.58

- Neuralangelo 在 F1 score 平均最佳，代表 surface reconstruction 品質最高。
- Neuralangelo 在 PSNR 平均也最佳，代表高細節幾何與 appearance modeling 同時改善 rendering。
- COLMAP 對 outlier sparse point cloud 敏感，dense surface 可能 noisy 或缺失。

- NeuralWarp 可能把 sky/background 預測成 surface，這些 outlier 會大幅降低 F1。
- Neuralangelo 使用 NeuS 類 background network 處理背景，而非把背景誤重建為 foreground surface。

4.3 Level of Details

論文用不同 hash resolution 的輸出展示 progressive LoD。Level 4 這類 coarse resolution 會漏掉 tree、table、bike rack 等細節；隨著 fine resolutions 啟用，這些 missing surfaces 可以逐步恢復。這也說明 hash encoding 沒有嚴格空間 hierarchy 的好處：fine levels 可以補回 coarse levels 沒有表示出的結構。

LoD 實驗的重點

這個實驗不只是展示細節變多，而是在支持方法設計：大型平面與細薄結構都需要跨 cell 的 normal consistency 與逐步釋放高解析度 feature。單靠 coarse grid 的連續性不夠。

4.4 Ablations

消融項目	拿掉後的現象	原因
Curvature regularization	surface 出現不自然 sharp transitions 與噪聲。	L_curv 是 smoothness prior，抑制過高 curvature。
Topology warmup	concave shapes 較難形成。	初始 SDF 近似 sphere；若一開始 curvature 太強，會保持 topology，阻礙凹形結構生成。
Numerical gradient	normal 與 geometry 容易 noisy。	analytical gradient 只更新局部 hash cell。
Progressive activation	NG 會太平滑，細節恢復不足。	fine grids 需要在適當尺度被啟用，而不是一開始被粗尺度目標平滑掉。

Appendix：補充細節整理

A. Additional Hyper-parameters

Hyperparameter	設定	解讀
Region of interest	假設在 unit sphere 內。	沿用 NeuS / VolSDF / IDR 類方法設定。
Total iterations	500k。	作者指出目前 random pixel sampling 效率不高，需要長訓練降低 stochasticity。
Learning rate	1e-2；5k linear warmup；300k 與 400k 各 decay 10 倍。	搭配 hash grid 與 shallow MLP 的高 LR 設定。
Optimizer	AdamW，weight decay = 1e-2。	抑制單一 hash resolution feature 主導。
w_eik	0.1。	控制 eikonal regularization。
w_curv	linearly warm up 到 5e-4，並跟 learning rate schedule decay；每次 ϵ 降低時按 hash spacing factor 下降。	避免後期 finer details 被 curvature loss 過度平滑。
SDF MLP	1 layer。	hash grid 承擔主要 representation capacity。
Color MLP	4 layers。	負責 view-dependent color 與 appearance。
Batch size	DTU = 1；Tanks and Temples = 16。	依資料集與場景尺度調整。
Marching cubes	DTU resolution 512；Tanks and Temples resolution 2048。	大尺度場景需要更高 mesh extraction resolution。

B. Additional In-the-wild Results

- 額外展示 NVIDIA HQ Park 與 Johns Hopkins University 的 drone-captured videos。
- Camera intrinsics 與 poses 由 COLMAP 回復。
- 作者開源 Blender add-on，讓使用者根據 COLMAP sparse point cloud 互動式選取 ROI。
- 使用與 Tanks and Temples 相同的 setup / hyperparameters，也能重建 buildings、sculptures、trees、umbrellas、walkways 等複雜結構。
- 這支持 hyperparameter 設定具一定 generalizability，而非只對 benchmark 調參。

C. Additional Tanks and Temples Results

附錄比較 Geo-NeUS。Geo-NeUS 使用 COLMAP sparse point clouds 改善 geometry，但在 large-scale in-the-wild scenes 中，COLMAP points 常 noisy；使用 noisy point supervision 反而可能降低重建品質。

方法	Barn	Caterpillar	Courthouse	Ignatius	Meetingroom	Truck	Mean
NeuS	0.29	0.29	0.17	0.83	0.24	0.45	0.38
Geo-NeUS	0.33	0.26	0.12	0.72	0.20	0.45	0.35
Ours	0.70	0.36	0.28	0.89	0.32	0.48	0.50

D. Additional DTU Results

- Neuralangelo 在 Scan 40、63、69 等可產生更 smooth surfaces，也能在 Scan 63、118 產生更 sharp details。
- Scan 122 的物體多為 diffuse material 且紋理較簡單，因此相較 baseline 的改進不明顯。
- Scan 69 高反光材質下，Neuralangelo 可能漏掉 button / eyes 等細節；作者認為這與 Instant-NGP hash encoding 在 reflective scenes 的弱點一致。
- DTU PSNR 只評估 foreground object，因背景相對簡單，需使用 object masks。

Scan 83 mask	NeuS Chamfer	NeuralWarp Chamfer	Ours Chamfer	解讀
IDR masks	1.48	1.20	1.29	原始 IDR mask 漏標部分物體，也不包含承載物體的 brick。
作者重標 masks	0.99	0.73	0.76	修正 mask 後所有方法都改善，說明評估 mask 對 Chamfer 有明顯影響。

E. Additional Ablations

項目	設計 / 結果	意義
Per-image latent embedding	Tanks and Temples 加入 NeRF-W 類 per-image appearance encoding。	可處理 video frame 間 exposure variation，減少 floaters。
Curvature strength decay	每次 ϵ 降低時，按 hash resolution spacing factor 降低 w_{curv} 。	保留 finer details，避免後期仍被強平滑。
NG vs AG normals	訓練結束時 ϵ 已接近 finest grid size，NG 與 AG 法線幾乎相同。	numerical gradient 主要在訓練前中期提供 smoothing / non-local update。
Intrinsic decomposition color network	albedo branch + shading branch；最終 $C = \text{sigmoid}(C_a + C_s)$ 。	shading 可解釋 view-dependent effects，但 homogeneous regions 可能被 carve away，未優於 IDR color network。

Computation Time

方法	Training time / iter	Inference time	說明
NeuS	0.16 s	0.19 s	8-layer SDF MLP，較慢。
AG	0.10 s	0.08 s	analytical gradient，最快但品質差。
NG (Ours)	0.12 s	0.08 s	numerical gradient 比 AG 訓練慢約 1.2 倍，但仍快於 NeuS；inference 不需 NG。

F. Frequency Encoding 推導

附錄比較 Fourier frequency encoding 與 hash encoding。Fourier encoding 的 $\phi_l(x) = [\sin(2^l \pi x), \cos(2^l \pi x)]$ ，對位置的導數仍是連續函數，且導數中仍含 x ，因此可以計算二階導數。這代表傳統 Fourier-MLP 不會遇到 hash encoding 那種 grid cell locality 問題。

不過作者也指出，即使 Fourier encoding 沒有 locality 問題，coarse-to-fine 的 ϵ schedule 仍可改善 optimization。實驗中 DTU Chamfer 從 0.84 改善到 0.79，表示 progressive optimization 本身也有價值。

圖表重點索引

圖 / 表	內容	應讀出的結論
Fig. 1	courthouse 3D mesh 與 surface normal。	Neuralangelo 能從 RGB video 取得大尺度高細節 mesh。
Fig. 2	analytical gradient vs numerical gradient 反傳範圍。	numerical gradient 讓 update 跨越局部 hash cell。
Fig. 3	DTU qualitative comparison。	Ours 比 NeuS / NeuralWarp 有更準確且高 fidelity 的 surface。
Fig. 4	AG / AG+P / NG / NG+P 消融。	NG+P 是必要組合；單獨 AG 或 NG 都不夠。
Table 1	DTU quantitative。	Ours mean Chamfer 0.61 · mean PSNR 33.84。
Fig. 5	Tanks qualitative。	Ours 對大尺度 scene 的細節保留更好。
Fig. 6	不同 hash resolution 的 LoD。	fine levels 能補回 coarse levels 漏掉的 structures。
Table 2	Tanks quantitative。	Ours mean F1 0.50 · mean PSNR 27.24。
Fig. 7	curvature 與 topology warmup 消融。	L_curv 改善平滑；warmup 幫助 concave shape。
Fig. 12	DTU Scan 83 masks。	evaluation mask 會顯著影響 Chamfer 結果。
Fig. 13–15	appearance embedding、w_curv decay、AG/NG normal。	補強方法穩定性與解釋 numerical gradient 的訓練角色。
Fig. 16–17	intrinsic decomposition color network。	decomposition 未提升 surface quality · default color network 較穩。
Table 5	計算時間。	NG 訓練略慢於 AG，但仍比 NeuS 快；inference 與 AG 相同。

方法優點、限制與實作注意

面向	整理
優點	不用 depth / segmentation / sparse point supervision；能處理 object-centric 與 large-scale scenes；幾何與 rendering 指標都提升；inference 較 NeuS 快。
限制	訓練 iteration 長；random pixel sampling 效率不高；reflective scenes 仍可能失敗；numerical gradient 增加 training SDF queries。
實作要點	必須正確做 central difference、 ϵ schedule、hash level activation、w_curv warmup/decay、background modeling 與 per-image appearance embedding。
最容易誤解處	numerical gradient 不是為了最終 inference normal 更準，而是為了訓練中讓 eikonal / curvature loss 產生 non-local smoothing updates。
可延伸方向	更有效的 ray / pixel sampling；更 robust 的 reflective material modeling；更 principled intrinsic decomposition；更快的 large-scene optimization。

口頭報告時的主線

- 先說問題：NeRF render 好但 surface 不明確；SDF surface 明確但 MLP 細節不足；hash grid 細節強但導數訓練有問題。
- 再說洞察：hash encoding 的 analytical gradient 只影響 local cell，因此 eikonal regularization 無法保證跨 cell normal consistency。
- 再說方法：用 numerical gradient 讓 normal 計算跨 cell；用 ϵ schedule 與 progressive hash activation 從粗到細訓練。
- 再說結果：DTU mean Chamfer 0.61 / PSNR 33.84；Tanks mean F1 0.50 / PSNR 27.24。
- 最後說限制：訓練長、random sampling 效率低、反光材質仍弱，這些是 future work。

最精簡的技術記憶句

Neuralangelo = NeuS-style SDF rendering + Instant-NGP hash grid + numerical-gradient smoothing + progressive LoD activation。